

M todo Iterativo dos Gradientes Conjugados

Trabalho 2

Leonardo Peres Albertazzi Drummond
Marco Antonio Tronco Felix
Eduardo de Mendon a Freire
Jo o Pedro Pe anha Cotrim
Carlos Augusto Bert o Rodrigues
Andre Pac fico

7 de junho de 2026

1 Introdu  o

O M todo dos Gradientes Conjugados (CG – *Conjugate Gradient*)   um dos algoritmos iterativos mais potentes e eficientes para a resolu  o de sistemas de equa  es lineares de grande porte na forma:

$$Ax = b \tag{1}$$

onde $A \in \mathbb{R}^{n \times n}$ representa uma matriz sim trica e positiva definida (SPD), $b \in \mathbb{R}^n$   o vetor de termos independentes, e $x \in \mathbb{R}^n$   o vetor de inc gnitas a ser computado.

Ao contr rio dos m todos diretos tradicionais como a Elimina  o de Gauss ou a Fatora  o de Cholesky, cuja complexidade computacional   de ordem $\mathcal{O}(n^3)$, o m todo dos Gradientes Conjugados converge teoricamente no espa o de no m ximo n passos (em aritm tica exata). O custo por itera  o   dominado pelo produto matriz-vetor, gerando uma complexidade aproximada de $\mathcal{O}(n^2)$ para matrizes cheias ou $\mathcal{O}(m)$ para matrizes esparsas estruturadas com m elementos n o nulos, tornando-o ideal para problemas f sicos modelados por equa  es diferenciais.

2 Implementação

O método funciona gerando uma base de vetores ortogonais em relação ao produto interno definido pela matriz A (direções conjugadas), ou seja, direções que satisfazem $v_i^T A v_j = 0$ para todo $i \neq j$.

Abaixo encontra-se a modelagem matemática e lógica do algoritmo iterativo com base na sequência exata de cálculo apresentada no pseudocódigo de referência:

2.1 Algoritmo Matemático

1. **Inicialização:** Dado um chute inicial x_0 (geralmente adotado como o vetor de aproximações iniciais):

$$\begin{aligned} r_0 &= b - Ax_0 \quad (\text{Resíduo Inicial}) \\ v_0 &= r_0 \quad (\text{Direção de busca inicial}) \\ i &= 0 \end{aligned}$$

2. **Laço Iterativo:** Realizado de forma iterativa até que um critério de parada pré-estabelecido seja satisfeito (como a norma do resíduo cair abaixo de uma tolerância ϵ):

$$\alpha_i = \frac{v_i^T r_i}{v_i^T A v_i} \quad (\text{Comprimento do passo})$$

$$x_{i+1} = x_i + \alpha_i v_i \quad (\text{Solução aproximada})$$

$$r_{i+1} = r_i - \alpha_i A v_i \quad (\text{Novo resíduo})$$

$$\beta_i = -\frac{v_i^T A r_{i+1}}{v_i^T A v_i} \quad (\text{Fator de correção / Novo comprimento de passo \&})$$

$$v_{i+1} = r_{i+1} + \beta_i v_i \quad (\text{Nova direção de busca})$$

$$i = i + 1$$

3 Matriz Exemplo e Casos de Teste

Para validar o comportamento numérico e a taxa de convergência do algoritmo dos Gradientes Conjugados (CG), utilizou-se o experimento proposto no livro-texto. O caso de estudo consiste em uma matriz esparsa A de dimensões 500×500 , cuja construção foi realizada através das seguintes etapas:

1. Atribuição do valor 1.0 a todas as posições da diagonal principal ($a_{ii} = 1.0$).
2. Preenchimento das posições fora da diagonal com números aleatórios extraídos de uma distribuição uniforme no intervalo $[-1, 1]$, garantindo a simetria inicial da matriz de modo que $A = A^T$.
3. Aplicação de um filtro de esparsidade comandado pelo parâmetro de limiar τ : qualquer elemento fora da diagonal principal que satisfaça $|a_{ij}| > \tau$ é substituído pelo valor zero.

Como descrito na literatura teórica, para valores de τ muito próximos de zero, o sistema gera uma matriz bem-condicionada e estritamente positiva definida. À medida que o valor de τ aumenta, tanto a densidade de elementos não nulos quanto o número de condicionamento pioram, fazendo com que a matriz perca a propriedade de ser positiva definida para limiares mais altos (como $\tau = 0.2$).

3.1 Análise das Propriedades da Matriz

Antes da execução dos métodos numéricos, realizou-se uma análise estrutural e espectral da matriz gerada para cada valor do parâmetro τ . A Tabela 1 documenta o número de condicionamento ($\kappa(A)$), a densidade de elementos não-nulos e a verificação matemática da condição de matriz Simétrica Positiva Definida (SPD).

Tabela 1: Propriedades estruturais e espectrais da matriz 500×500 em função de τ .

Limiar (τ)	Condicionamento $\kappa(A)$	Simétrica?	PD?	Diagonal Dominante?
0.01	1.0815	Sim	Sim	Sim
0.05	2.3932	Sim	Sim	Não
0.10	459.37	Sim	Não	Não
0.20	824.99	Sim	Não	Não
0.50	824.99	Sim	Não	Não
1.00	5560.5	Sim	Não	Não

Os resultados empíricos obtidos demonstram que o aumento do limiar τ aumentam o número de condicionamento da matriz. Na qual, esse fator irá gerar impactos no fator de convergência dos métodos iterativos.

Além disso, a partir de $\tau = 0.10$ a matriz deixa de ser positiva definida e a partir de $\tau = 0.05$ ela deixa de ser diagonal dominante.

3.2 Resultados e Comparação entre Métodos

O sistema linear $Ax = b$ foi resolvido adotando-se um vetor x aleatório, usando o valor de Ax como valor de b e tomando um vetor de aproximação inicial x_0 com 1 em todas as entradas. Foram confrontados os desempenhos do Método dos Gradientes Conjugados (CG), Método de Jacobi e Método de Gauss-Seidel sob uma tolerância estipulada de $\epsilon = 10^{-8}$ ou um limite máximo de 2000 iterações.

A Tabela 2 detalha o número de iterações necessárias para a convergência de cada método em seus respectivos cenários.

Denota-se que a cada vez que aumentamos o limiar τ o número de iterações aumenta para convergência dos métodos iterativos. Com isso, causando a divergência dos métodos de Jacobi e Gauss-Seidel.

No entanto, a matriz apresenta um comportamento interessante no valor de $\tau = 1$, o método dos Gradientes Conjugados volta a convergir dentro do limite máximo de iterações.

A Tabela 3 detalha o valor de erro relativo final na convergência ou divergência de cada método em seus respectivos cenários.

Tabela 2: Comparação do número de iterações para convergência ($\epsilon = 10^{-8}$).

Cenário de Teste	Gradientes Conjugados	Método de Jacobi	Gauss-Seidel
Matriz $\tau = 0.01$	5 iterações	7 iterações	5 iterações
Matriz $\tau = 0.05$	12 iterações	20 iterações	12 iterações
Matriz $\tau = 0.10$	156 iterações	Divergiu	Divergiu
Matriz $\tau = 0.20$	Parou no máximo de iterações	Divergiu	Divergiu
Matriz $\tau = 0.50$	Parou no máximo de iterações	Divergiu	Divergiu
Matriz $\tau = 1.00$	1231 iterações	Divergiu	Divergiu


Tabela 3: Comparação do erro relativo resultante ($\frac{\|b-Ax\|_2}{\|b\|_2}$).

Cenário de Teste	Gradientes Conjugados	Método de Jacobi	Gauss-Seidel
Matriz $\tau = 0.01$	2.705×10^{-09}	1.959×10^{-11}	6.499×10^{-11}
Matriz $\tau = 0.05$	9.154×10^{-09}	2.360×10^{-09}	3.098×10^{-10}
Matriz $\tau = 0.10$	8.702×10^{-09}	2.859×10^{94}	3.960×10^{143}
Matriz $\tau = 0.20$	2.212×10^{-03}	INF	INF
Matriz $\tau = 0.50$	2.212×10^{-03}	INF	INF
Matriz $\tau = 1.00$	9.547×10^{-09}	INF	INF


Comparando o cenário que todos os métodos convergiram, $\tau = 0.01$ e $\tau = 0.05$ vemos que os métodos de Jacobi e Gauss-Seidel apresentaram menor erro relativo que o Gradientes Conjugados, no entanto, analisando todos os resultados o Gradientes Conjugados mostrou-se mais eficiente, devido a apresentar convergência em 4 casos de 6 testes feitos.

3.3 Gráficos de Log(r) x iterações

3.3.1 Matriz $\tau = 0.01$




3.3.2 Matriz $\tau = 0.05$



Até $\tau = 0.05$ a matriz é positiva definida, o que trouxe um comportamento de decrescimento linear para o gráfico.


3.3.3 Matriz $\tau = 0.10$




Diferente dos valores de τ anteriores esse gráfico retornou um comportamento não monótono, apresentando pequenas "barrigas", no entanto, acelera na descida final resultando na convergência do método.

Além disso, diferente das matrizes anteriores, a matriz com valor de $\tau = 0.1$ se mostrou não ser positiva definida o que afetou a maneira da convergência do método.

3.3.4 Matriz $\tau = 0.20$




3.3.5 Matriz $\tau = 0.50$



Os gráficos acima ilustram perfeitamente o comportamento de estagnação e oscilação caótica do Método dos Gradientes Conjugados quando aplicado à matriz indefinida com

limiar $\tau = 0.50$, atingindo o limite configurado de 2000 iterações sem alcançar a convergência. Ao contrário do cenário estável visto anteriormente, a perda da propriedade positiva definida da matriz introduz autovalores negativos ou nulos, o que sabota a minimização consistente da energia do sistema. Como consequência, o algoritmo perde a sua trajetória ótima de descida e entra em um regime de busca desordenada, fazendo com que o resíduo fique "preso" e flutue de forma ruidosa em uma faixa alta de erro, majoritariamente entre 10^{-1} e 10^{-3} .

3.3.6 Matriz $\tau = 1.00$



Diferente dos gráficos anteriores apesar de possuir um comportamento oscilatório caótico, o gráfico apresentou um comportamento decrescente, o que resultou na sua futura convergência.

4 Comparação com as matrizes do trabalho 1

Para comparar a performance do método em detrimento dos outros métodos iterativos realizamos o teste nas 12 matrizes utilizadas no trabalho anterior. Foram confrontados os desempenhos do Método dos Gradientes Conjugados (CG) sob uma tolerância estipulada de $\epsilon = 10^{-8}$ ou um limite máximo de 3000 iterações.

Tabela 4: Comparação do número de iterações e do erro relativo nas matrizes do trabalho 1.

Matriz	n	erro relativo	Gradientes Conjugados	SPD?
bcsstk01	48	3.894×10^{-9}	142 iterações	sim
bfw62b	62	5.637×10^{-9}	30 iterações	não
bcsstm02	66	2.501×10^{-16}	12 iterações	sim
bcsstk03	112	9.148×10^{-9}	444 iterações	sim
bcsstk04	132	9.392×10^{-9}	512 iterações	sim
bcsstm22	138	4.280×10^{-9}	55 iterações	sim
bfw398b	398	9.140×10^{-9}	38 iterações	não
494_bus	494	9.681×10^{-9}	1124 iterações	sim
dwb512	512	3.732×10^{-9}	16 iterações	não
nos6	675	8.519×10^{-9}	672 iterações	sim
gr_30_30	900	7.547×10^{-9}	63 iterações	sim
1138_bus	1138	9.916×10^{-9}	2017 iterações	sim

Denota-se que diferente do trabalho 1, o método iterativo dos Gradientes Conjugados convergiu para todas as matrizes apresentando um erro relativo médio na ordem de 10^{-9} . Demonstrando assim a maior eficiência desse método em relação aos outros.

Vale ressaltar que para as matrizes bcsstm02 e bcsstm22 que são diagonais ela não convergiu em duas iterações, diferente do que aconteceu com os métodos de Gauss-Seidel e Jacobi.

5 Conclusão

A investigação prática realizada neste relatório permitiu mapear com clareza o comportamento assintótico e os limites de estabilidade do Método dos Gradientes Conjugados (CG) em comparação aos métodos estacionários de Jacobi e Gauss-Seidel. Os experimentos empíricos evidenciaram que o parâmetro de limiar τ atua diretamente sobre as propriedades espectrais da matriz de teste, ditando o seu número de condicionamento e a preservação de características algébricas fundamentais, tais como a dominância diagonal e a positividade definida.

Ficou demonstrada a sensibilidade dos métodos de Jacobi e Gauss-Seidel às restrições do critério de convergência por diagonal dominante. À medida que o aumento de τ povoou a matriz com coeficientes aleatórios fora da diagonal principal, ambos os métodos sofreram divergências catastróficas abruptas já a partir de $\tau \geq 0.10$, atingindo valores de erro relativo em escalas de *overflow* numérico (INF). Em contrapartida, a formulação expandida do método de Gradientes Conjugados implementada neste trabalho revelou-se muito mais resiliente às perturbações espectrais devido ao cálculo dinâmico do fator de correção β_i , que força a ortogonalidade entre as direções de busca a cada iteração. Embora o método tenha estagnado sob oscilações caóticas nos cenários onde a matriz tornou-se estritamente indefinida ($\tau = 0.20$ e $\tau = 0.50$), ele evitou o colapso numérico imediato por explosão de resíduo observável nas técnicas estacionárias.

O fenômeno mais marcante do estudo manifestou-se no cenário limite de $\tau = 1.00$. Embora a matriz tenha atingido o seu maior número de condicionamento registrado ($\kappa(A) = 5560.5$) e se estruturado de forma densa e indefinida, o método dos Gradientes

Conjugados foi capaz de reestabelecer a sua trajetória de descida e alcançar a convergência em 1231 iterações sob um erro relativo na ordem de 10^{-9} . Esse comportamento valida empiricamente propriedades associadas a grandes sistemas aleatórios descritos na literatura matemática, nos quais o acúmulo de componentes simétricas densas propicia um rearranjo dos autovalores residuais que, uma vez purgados nas fases iniciais de estagnação ruidosa, engatam um regime de superconvergência tardia na reta final do algoritmo.

Por fim, a validação do algoritmo sobre o banco de dados do Trabalho 1 consagrou o Método dos Gradientes Conjugados como uma ferramenta amplamente superior e robusta para problemas de engenharia e modelagem física. O algoritmo alcançou a convergência em 100% das doze matrizes testadas — incluindo malhas severamente esparsas e de grande porte como a `1138.bus` — mantendo erros relativos rigidamente controlados na ordem de 10^{-9} a 10^{-16} . Esclareceu-se também que, para matrizes diagonais, o método requer um número de passos condicionado à quantidade de autovalores distintos no espectro da matriz, desmistificando a falsa superioridade das duas iterações observadas nos métodos estacionários, as quais decorriam de uma interrupção precoce por divergência e não de convergência real. O método dos Gradientes Conjugados consolida-se, portanto, como a solução de maior confiabilidade, eficiência computacional e previsibilidade geométrica para a resolução de sistemas lineares simétricos de alta complexidade.